



第七章 空间数据挖掘

1

空间数据挖掘概述

2

空间聚类

3

空间关联分析

4

分类与预测

4

异常值分析



1 空间数据挖掘概述

➤ 何为数据挖掘？

- 数据挖掘也称为数据库中知识发现，一般是指从包含大量的、不完全的、有噪声的、模糊的、随机的实际应用数据的数据库或数据仓库中提取隐含在其中的、人们事先不知道的，但又是潜在有用的信息、只是或模式的过程。提取的只是可以表现为概念、规则、规律、模式等形式。

➤ 何为空间数据挖掘？

- 空间数据挖掘的对象是空间数据库，其目的是从空间数据库中提取隐含的、人们感兴趣的空間模式和特征。



空间数据挖掘概述

➤ 空间数据挖掘的发展





1


空间数据挖掘概述

- 空间数据与其他类型数据的一个重要区别就是它的空间特性，所以空间数据挖掘对于一般的数据挖掘具有以下特点：
 - 应用范围广，可对任何具有空间特性的数据进行挖掘；
 - 挖掘算法多，除一般数据挖掘外，还有云理论、探索性数据分析等；
 - 只是表达方式多，数据的空间特性可提高研究者对现实世界的理解和认知程度；
 - 数据量大，空间数据来源丰富，具有海量特征，存取复杂。



1 空间数据挖掘概述

➤ 空间数据挖掘步骤





1 空间数据挖掘概述

➤ 空间数据挖掘任务

- 空间数据挖掘的目标是**从数据库中发现有意义的模式、特征和规律。**
- 空间数据挖掘的主要任务有：
 - ①空间数据特征比较
 - ②空间聚类分析
 - ③空间分类
 - ④空间关联
 - ⑤空间模式分析
- 除以上外还有专家认为应该包括**数据泛化和偏差分析**。其中数据泛化的目的使对数据进行浓缩，对数据的总体特征进行描述，将数据从较低的个体层次抽象到较高的总体层次上。偏差分析的目的使从数据库中检测出偏差。



1 空间数据挖掘概述

➤ 空间数据挖掘对数据的处理方法

- 空间数据挖掘对空间数据的处理方法：

- ① 将空间作为整体框架，同一空间区域范围内的数据不考虑空间特征要素，研究各种区域统计指标计算、系统相关模型
- ② 利用变异函数、空间自相关指数等方法，研究数据的空间分布特征
- ③ 将空间要素是转换为一维属性数据或作为属性数据的乘积因子进行分析操作
- ④ 将不同数据按图层分布进行空间配准后，对数据进行重采样，形成统一格式的数据，然后利用一般的分析方法进行分析操作



1 空间数据挖掘概述

➤ 空间数据挖掘的知识类型

- 空间数据挖掘所使用的方法与发现的知识类型密切相关。因此，在讨论空间数据挖掘的方法之前，有必要对空间数据挖掘发现的知识类型进行归纳。通常可将空间数据挖掘发现的知识规则分为以下几种：

- ✓ 普遍的几何知识
- ✓ 面向对象的知识
- ✓ 空间关联规则
- ✓ 空间聚类规则
- ✓ 空间特征规则
- ✓ 空间区分规则

- ✓ 空间分类规则
- ✓ 空间回归规则
- ✓ 空间依赖规则
- ✓ 空间预测规则
- ✓ 空间演变规则
- ✓ 空间例外



1 空间数据挖掘概述

➤ 空间数据挖掘方法

- 机器学习方法

- ✓ 神经网络、决策树、贝叶斯网络等

- 数字图像识别

- ✓ 小波分析、监督分析、CONQUEST等

- 不确定性分析

- ✓ 粗集、模糊集理论、云理论等

- 确定集合方法

- ✓ 概率论、空间聚类、空间分析、空间关联规则归纳等



2

空间聚类

➤ 空间聚类的要求


- **可伸缩性；** 许多聚类算法在小于 200 个数据对象的小数据集上工作得很好；但是，一个大规模数据库可能包含几百万个对象，在这样的大数据集样本上进行聚类可能会导致有偏的结果。我们需要具有高度可伸缩性的聚类算法。
- **发现任意形状的聚类；** 许多聚类算法基于欧几里得或者曼哈顿距离度量来决定聚类。基于这样的距离度量的算法趋向于发现具有相近尺度和密度的球状簇。
- **用于决定输入参数的领域知识最小化**
- **对噪声数据不敏感；** 绝大多数现实中的数据库都包含了孤立点，缺失，或者错误的数据。
- **对于输入记录的顺序不敏感；**
- **处理高维数据；** 一个数据库或者数据仓库可能包含若干维或者属性。许多聚类算法擅长处理低维的数据，可能只涉及两到三维。人类的眼睛在最多三维的情况下能够很好地判断聚类的质量。在高维空间中聚类数据对象是非常有挑战性的，特别是考虑到这样的数据可能分布非常稀疏，而且高度偏斜。

2

空间聚类

➤ 空间聚类的主要算法

- 空间聚类的主要方法有五大类：**划分聚类算法、层次聚类算法、基于密度的方法、基于网格的方法和基于模型的聚类方法。**





2

空间聚类

➤ 空间聚类的主要算法

• 划分聚类算法

- ✓ 主要包括：K-means、K-medoids、PAM、CLARA、K-模、K-原型、EM和CLARANS等。基本思想：给定一个包含 n 个对象或数据的集合，将数据集划分为 k 个子集，其中每个子集均代表一个聚类($k \leq n$)，划分方法首先创建一个初始划分，然后利用循环再定位技术，即通过移动不同划分中的对象来改变划分内容。
- ✓ 典型的算法说明：K-means算法是首先从 n 个数据对象随机地选择 k 个对象，每个对象初始地代表了一个簇中心，对剩余的每个对象，根据其与各个簇中心的距离，将它赋给最近的簇，然后重新计算每个簇的平均值。这个过程不断重复，直到准则函数收敛（说明：一般都采用均方差作为标准测度函数）。



2

空间聚类

➤ 空间聚类的主要算法

- 层次聚类算法

- ✓ 层次聚类方法是通过将数据组织为若干组并形成一个相应的树来进行聚类的，层次聚类方法又可分为自顶向下的**分裂算法**和自底向上的**凝聚算法**两种。
- ✓ 分裂聚类算法，首先将所有对象置于一个簇中，然后逐渐细分为越来越小的簇，直到每个对象自成一簇，或者达了某个终结条件，这里的终结条件可以是簇的数目，或者是进行合并的阈值。而凝聚聚类算法正好相反，首先将每个对象作为一个簇，然后将相互邻近的合并为一个簇，直到所有的对象都在一个簇中，或者某个终结条件被满足。



2

空间聚类

➤ 空间聚类的主要算法

• 基于密度的方法

- ✓ 绝大多数划分方法基于对象之间的距离进行聚类，这样的方法只能发现球状的类。因此，出现了基于密度的聚类方法，其主要思想是：只要邻近区域的密度(对象或数据点的数目) 超过某个阈值，就继续聚类，这样的方法可以过滤“噪声”数据，发现任意形状的类。从而克服基于距离的方法只能发现类圆形聚类的缺点。代表性算法有：
 - ✓ DBSCAN 算法、OPTICS 算法、DENCLUE算法等。
 - ✓ DBSCAN 算法可以有效地发现具有任意形状的类，并正确地处理噪声数据。除此之外，该算法还具有实现简单、聚类效果较好等优点。
 - ✓ OPTICS 算法是一种基于类排序方法。该算法并不明确产生一个聚类，而是为自动交互的聚类分析计算出一个增强聚类顺序。这个顺序代表了数据的基于密度的聚类结构。



2

空间聚类

➤ 空间聚类的主要算法

- 基于网格法

- ✓ 主要思想是将空间区域划分若干个具有层次结构的矩形单元，不同层次的单元对应于不同的分辨率网格，把数据集中的所有数据都映射到不同的单元网格中，算法所有的处理都是以单个单元网格为对象，其处理速度要远比以元组为处理对象的效率要高的多。代表性算法有：STING算法、CLIQUE 算法、WAVE-CLUSTER 算法等。
- ✓ STING 算法首先将空间区域划分为若干矩形单元，这些单元形成一个层次结构，每个高层单元被划分为多个低一层的单元。单元中预先计算并存储属性的统计信息，高层单元的统计信息可以通过底层单元计算获得。这种算法的优点是效率很高，而且层次结构有利于并行处理和增量更新；其缺点是聚类的边界全部是垂直或是水平的，与实际情况可能有比较大的差别，影响聚类的质量。



2

空间聚类

➤ 空间聚类的主要算法

- 基于模型法


- ✓ 给每一个聚类假定一个模型，然后去寻找能够很好地满足这个模型的数据集。常用的模型主要有两种：一种是统计学的方法，代表性算法是COBWEB算法；另一种是神经网络的方法，代表性的算法是竞争学习算法。COBWEB 算法是一种增量概念聚类算法。这种算法不同于传统的聚类方法，它的聚类过程分为两步：首先进行聚类，然后给出特征描述。因此，分类质量不再是单个对象的函数，而且也加入了对聚类结果的特征性描述。竞争学习算法属于神经网络聚类。它采用若干个单元的层次结构，以一种“胜者全取”的方式对系统当前所处理的对象进行竞争。

2

空间聚类

➤ 空间聚类分析的实现

- 空间聚类分析可以分为**基于点**和**基于面**两种方法。基于点的方法需要时间准确的地理位置，基于面的的方法是运用其区域内的平均值[1]。到底用哪种方法，关键取决于数据，“基于点的方法并不总是优于基于面的方法。”







2 空间聚类

➤ ArcGIS中空间聚类的实现


Inverse distance, inverse distance squared (impedance)



Distance band (sphere of influence)



Zone of indifference



2

空间聚类

➤ ArcGIS中空间聚类的实现

• 基于面的全局聚类检验

- ✓ Moran's I 指数是最早应用于全局聚类检验的方法。它检验整个研究区中临近地区间是相似、相异（空间正相关、负相关），还是相互独立的。Moran's I 指数计算公式：
- ✓ 这里， N 是研究区内地区总数， ω_{ij} 是空间权重， x_i 和 x_j 分别是区域 i 和 j 的属性， $\bar{x}$ 是属性的平均值。
- ✓ Moran's I 指数数值处于-1到1之间，值接近1是表明具有相似的属性集聚在一起；值接近-1时表明具有相异的属性集聚在一起。如果Moran's I 指数接近于0则表示属性是随机分布的，或者不存在空间自相关性。
- ✓ 与Moran's I 指数相似，吉瑞C指数（Geary's C）也是全局聚类检验的一个指数，其公式为：吉瑞C指数值通常在0到2之间。虽然2不是一个严格的上界。其值为1时，表示属性的观察值在空间上是相互独立的，值在0到1之间表示空间正相关，值在1到2之间时表示空间负相关。因此，吉瑞C指数与Moran's I 指数刚好相反。



2

空间聚类

➤ ArcGIS中空间聚类的实现

• 基于面的局部聚类检验

- ✓ Anselin提出了一个局部莫兰指数 (Local Moran Index) 用来检验局部地区是否存在相似或者相异的观察值聚集在一起。区域 i 的局部莫兰指数用来度量区域 i 和它领域之间的关联程度，定义为：
- ✓ 正的 I_i 表示一个高值被高值所包围（高-高）或者是一个低值被低值所包围（低-低）；负的 I_i 表示一个低值被高值所包围或与之相反的情况。
- ✓ 类似地， G_i 指数 (Getis and Ord, 1992) 用来检验局部地区是否存在显著地高值或低值。 G_i 定义如下：
- ✓ 公式中的符号与Moran's I 指数相同，式中对 j 的累加不包括区域 i 本身，即 $j \neq i$ ；高的 G_i 代表高值的样本集中在一起，而低的 G_i 值表示低值的样本集中在一起。



3

空间关联分析

➤ 关联规则挖掘：

- 在交易数据、关系数据或其他信息载体中，查找存在于项目集合或对象集合之间的频繁模式、关联、相关性、或因果结构。

➤ 应用：

- 购物篮分析、交叉销售、产品目录设计、 loss-leader analysis、聚集、分类等。

➤ 举例：

- 规则形式： “Body ® Head [support, confidence]” .
- $\text{buys}(x, \text{"diapers"}) \text{ ® } \text{buys}(x, \text{"beers"}) [0.5\%, 60\%]$
- $\text{major}(x, \text{"CS"}) \text{ ^ } \text{takes}(x, \text{"DB"}) \text{ ® } \text{grade}(x, \text{"A"}) [1\%, 75\%]$



3 空间关联分析

➤ 给定:

- (1)交易数据库
- (2)每笔交易是: 一个项目列表 (消费者一次购买活动中购买的商品)

➤ 查找:

- 所有描述一个项目集合与其他项目集合相关性的规则
- E.g., 98% of people who purchase tires and auto accessories also get automotive services done


➤ 应用:

- 护理用品 (商店应该怎样提高护理用品的销售?)
- 家用电器 (其他商品的库存有什么影响?)
- 在产品直销中使用附加邮寄
- Detecting “ping-pong” ing of patients, faulty “collisions”

3

空间关联分析

➤ 关联规则度量：支持度与可信度



- 查找所有的规则 $X \& Y \rightarrow Z$ 具有最小支持度和可信度
- 支持度, s , 一次交易中包含 $\{X, Y, Z\}$ 的可能性
- 可信度, c , 包含 $\{X, Y\}$ 的交易中也包含 Z 的条件概率

交易ID	购买的商品
2000	A,B,C
1000	A,C
4000	A,D
5000	B,E,F

- 设最小支持度为50%, 最小可信度为 50%, 则可得
- $A \rightarrow C$ (50%, 66.6%)
- $C \rightarrow A$ (50%, 100%)



3 空间关联分析

➤ 布尔 vs. 定量 关联 (基于处理数据的类型)

- $\text{buys}(x, \text{"SQLServer"}) \wedge \text{buys}(x, \text{"DMBook"}) \circledast \text{buys}(x, \text{"DBMiner"})$ [0.2%, 60%]
- $\text{age}(x, \text{"30..39"}) \wedge \text{income}(x, \text{"42..48K"}) \circledast \text{buys}(x, \text{"PC"})$ [1%, 75%]

➤ 单维 vs. 多维 关联 (例子同上)

➤ 单层 vs. 多层 分析

- 那个品种牌子的啤酒与那个牌子的尿布有关系?

➤ 各种扩展

- 相关性、因果分析: 关联并不一定意味着相关或因果
- 最大模式和闭合相集
- 添加约束: 如, 哪些“小东西”的销售促发了“大家伙”的买卖?

3

空间关联分析

➤ 关联规则挖掘：一个例子

交易ID	购买商品
2000	A,B,C
1000	A,C
4000	A,D
5000	B,E,F

最小值尺度 50%
最小可信度 50%

频繁项集	支持度
{A}	75%
{B}	50%
{C}	50%
{A,C}	50%

- 对于 $A \rightarrow C$:
 - $\text{support} = \text{support}(\{A, C\}) = 50\%$
 - $\text{confidence} = \text{support}(\{A, C\}) / \text{support}(\{A\}) = 66.6\%$
- **Apriori的基本思想**: 频繁项集的任何子集也一定是频繁的



3 空间关联分析

➤ 关键步骤：挖掘频繁集

- **频繁集**：是指满足最小支持度的项目集合
 - ✓ **频繁集的子集也一定是频繁的**：如果 $\{AB\}$ 是频繁集，则 $\{A\}$ $\{B\}$ 也一定是频繁集
 - ✓ 从1到k (k-频繁集) 递归查找频繁集
- 用得到的频繁集生成关联规则

3

空间关联分析

➤ 多层关联规则

- 项通常具有层次
- 底层的项通常支持度也低
- 某些特定层的规则可能更有意义
- 交易数据库可以按照维或层编码
- 可以进行共享的多维挖掘



TID	Items
T1	{111, 121, 211, 221}
T2	{111, 211, 222, 323}
T3	{112, 122, 221, 411}
T4	{111, 121}
T5	{111, 122, 211, 221, 413}



3 空间关联分析

➤ 多层关联规则

- 自上而下，深度优先的方法：
 - ✓ 先找高层的“强”规则：牛奶 -> 面包 [20%, 60%].
 - ✓ 再找他们底层的“弱”规则：酸奶 -> 黄面包 [6%, 50%].
- 多层关联规则的变种
 - ✓ 层次交叉的关联规则：酸奶 -> 面包房 黄面包
 - ✓ 不同种分层方法间的关联规则：酸奶 -> 面包房 面包



3 空间关联分析

➤ 多层关联规则

- **支持度不变:** 在各层之间使用统一的支持度
 - ✓ + 一个最小支持度阈值. 如果一个项集的父项集不具有最小支持度, 那他本身也不可能满足最小支持度。
 - ✓ - 底层项不会成为频繁集, 如果支持度太高会丢失底层关联规则; 太低会生成太多的高层关联规则
- **支持度递减:** 随着层次的降低支持度递减
 - ✓ 层与层独立
 - ✓ 用k-项集跨层过滤
 - ✓ 用项跨层过滤
 - ✓ 用项进行可控跨层过滤

3

空间关联分析


➤ 支持度不变多层挖掘

层 1

$\text{min_sup} = 5\%$

层 2

$\text{min_sup} = 5\%$






3 空间关联分析

➤ 支持度递减多层挖掘

层 1
 $\text{min_sup} = 5\%$

层 2
 $\text{min_sup} = 3\%$





3 空间关联分析

➤ 多层挖掘：深度优先

- 自顶向下，深度优先的方法：

- ✓ 先挖掘高层频繁项：牛奶 (15%), 面包 (10%)
- ✓ 再挖掘他们底层的相对较弱的频繁项：酸奶 (5%), 白面包 (4%)

- 跨层时对支持度的不同处理方法，对应了不同的算法：

- ✓ 层之间支持度不变：如果t的祖先是非频繁的，则不用考虑t
- ✓ 支持度随层递减：只考虑那些其祖先是频繁的/不可忽略的项



3 空间关联分析

➤ 数据挖掘查询的逐步精化

- 为什么要**逐步精化**

- ✓ 挖掘操作的代价可能高或低，结果可能细致或粗糙
- ✓ 在速度和质量之间折衷：逐步精化

- **超集覆盖特征：**

- ✓ 预存储所有正面答案—允许进一步正确性验证，而不必验证已经错误的

- **多步挖掘：**

- ✓ 先执行粗糙的、容易的操作 (超集覆盖)
- ✓ 然后在减少后的候选集上进行计算量大的算法 (Koperski & Han, SSD' 95).

3

空间关联分析

➤ 逐步求精空间关联规则挖掘

- 空间关系的**层次**:
 - ✓ “g_close_to” : 邻近, 接触, 交叉, 包含
 - ✓ 先搜索粗糙的关系然后再精化
- 空间关联规则的**两步算法**:
 - ✓ **粗糙空间计算** (用于过滤): 用 MBR 或 R-tree 做粗糙估计
 - ✓ **细致空间算法** (用于精化): 只计算已经通过空间计算的对象




Fig. 2. The hierarchy of topological relations.



3

空间关联分析

➤ 多维关联规则：概念

- 单维规则：

- ✓ $\text{buys}(X, \text{"milk"}) \rightarrow \text{buys}(X, \text{"bread"})$

- 多维规则：

- ✓ 维间关联规则 (维词不重复): $\text{age}(X, \text{"19-25"}) \wedge \text{occupation}(X, \text{"student"}) \rightarrow \text{buys}(X, \text{"coke"})$

- ✓ 混合维关联规则 (维词重复): $\text{age}(X, \text{"19-25"}) \wedge \text{buys}(X, \text{"popcorn"}) \rightarrow \text{buys}(X, \text{"coke"})$

- 类别属性：

- ✓ 有限个值, 值之间无顺序关系

- 数量属性：

- ✓ 数字的, 值之间隐含了顺序关系



3 空间关联分析

➤ 挖掘多维关联的技术

- 搜索频繁k-维词集合：

- ✓ 如: {age, occupation, buys} 是一个3-维词集合。

- ✓ 按照对 age 处理方式的不同，分为：

- 用静态方法把数值属性离散化：数值属性可用预定义的概念层次加以离散化。

- 带数量的关联规则：根据数据的分布动态的把数值属性离散化到不同的“箱”。


- 基于距离的关联规则：用数据点之间的距离动态的离散化

3

空间关联分析

➤ 数值属性的静态离散化

- 在挖掘之前用概念层次先离散化
- 数值被替换为区间范围
- 关系数据库中，要找到所有频繁k-维词需要k或k+1次表扫描。
- 适宜使用数据立方体
- N维立方体的每个单元对应一个维词集合
- 使用数据立方体速度更快



3

空间关联分析

➤ 带数量的关联规则


- 动态离散化数值属性

- ✓ Such that the confidence or compactness of the rules mined is maximized.

- 2-维数量关联规则: $A_{quan1} \wedge A_{quan2} \rightarrow A_{cat}$

- 用2-维表格把“邻近”的关联规则组合起来,例子:

- ✓ $age(X, "30-34") \wedge income(X, "24K - 48K") \rightarrow buys(X, "high\ resolution\ TV")$




3

空间关联分析

➤ ARCS (关联规则聚集系统)

• ARCS 流程

- ✓ 1. 分箱
- ✓ 2. 查找频繁维词集合
- ✓ 3. 聚集
- ✓ 4. 优化





空间关联分析

➤ ARCS的局限性

- 数值属性只能出现在规则的左侧
- 左侧只能有两个属性 (2维)
- ARCS 的改进
 - ✓ 不用基于栅格的方法
 - ✓ 等深分箱
 - ✓ 基于局部完整性 测度的聚集
 - ✓ “Mining Quantitative Association Rules in Large Relational Tables”
by R. Srikant and R. Agrawal.

3

空间关联分析

➤ 基于距离的关联规则挖掘

- 分箱的方法没有体现数据间隔的语义

价格 (\$)	等宽 (宽度\$10)	等深 (深度 2)	基于距离
7	[0,10]	[7,20]	[7,7]
20	[11,20]	[22,50]	[20,22]
22	[21,30]	[51,53]	[50,53]
50	[31,40]		
51	[41,50]		
53	[51,60]		

- 基于距离的分割是更有 “意义” 的离散化方法，考虑：

- ✓ 区间内密度或点的个数
- ✓ 区间内点的 “紧密程度”



3

空间关联分析

➤ 聚集和距离度量

- 记 $S[X]$ 为 N 个元组 $t_1, t_2, \dots, t_N$ 在属性集 X 上的投影
- 则 $S[X]$ 的直径:

$$d(S[X]) = \frac{\sum_{i=1}^N \sum_{j=1}^N dist_x(t_i[X], t_j[X])}{N(N-1)}$$

✓ $dist_x$: 距离量度, 如 欧几里德距离或 Manhattan



3 空间关联分析

➤ 聚集和距离度量

- 用直径 d 评估聚集 C_X 的密度, 其中

$$d(C_X) \leq d_0^X$$


$$|C_X| \geq s_0$$

- 查找聚集和基于距离的规则
 - ✓ 用密度阈值 d_0 代替支持度
 - ✓ 采用修改过的 BIRCH 聚集算法

3

空间关联分析


➤ 关联规则可视化Using Plane Graph



3

空间关联分析

➤ 关联规则可视化Using Plane Graph





4

分类与预测

➤ 分类：

- 预测分类标号（或离散值）
- 根据训练数据集和类标号属性，构建模型来分类现有数据，并用来分类新数据

➤ 预测：

- 建立连续函数值模型，比如预测空缺值

➤ 典型应用

- 信誉证实
- 目标市场
- 医疗诊断
- 性能预测



4

分类与预测

➤ 数据分类：两步过程

- 第一步，建立一个模型，**描述预定数据类集和概念集**
 - ✓ 假定每个元组属于一个预定义的类，由一个类标号属性确定
 - ✓ 基本概念：
 - **训练数据集**：由为建立模型而被分析的数据元组形成
 - **训练样本**：训练数据集中的单个样本（元组）
 - ✓ 学习模型可以用分类规则、判定树或数学公式的形式提供
- 第二步，使用模型，对将来的或未知的对象进行分类
 - 首先评估模型的预测准确率
 - ✓ 对每个测试样本，将已知的类标号和该样本的学习模型类预测比较
 - ✓ 模型在给定测试集上的准确率是正确被模型分类的测试样本的百分比
 - ✓ 测试集要独立于训练样本集，否则会出现“**过分适应数据**”的情况

4

分类与预测

➤ 第一步：建立模型

训练数据集

NAME	RANK	YEARS	TENURED
Mike	Assistant Prof	3	no
Mary	Assistant Prof	7	yes
Bill	Professor	2	yes
Jim	Associate Prof	7	yes
Dave	Assistant Prof	6	no
Anne	Associate Prof	3	no

分类算法


分类规则

**IF rank = 'professor'
OR years > 6
THEN tenured = 'yes'**

4

分类与预测

➤ 第二步：用模型进行分类





4

分类与预测

➤ 准备分类和预测的数据

- 通过对数据进行预处理，可以提高分类和预测过程的**准确性、有效性和可伸缩性**
 - ✓ **数据清理**：消除或减少噪声，处理空缺值，从而减少学习时的混乱；
 - ✓ **相关性分析**：数据中的有些属性可能与当前任务不相关；也有些属性可能是冗余的；删除这些属性可以加快学习步骤，使学习结果更精确；
 - ✓ **数据变换**：可以将数据概化到较高层概念，或将数据进行规范化；



4

分类与预测

➤ 比较分类方法

- 使用下列标准比较分类和预测方法：
 - ✓ **预测的准确率**：模型正确预测新数据的类编号的能力
 - ✓ **速度**：产生和使用模型的计算花销
 - ✓ **鲁棒性**：给定噪声数据或有空缺值的数据，模型正确预测的能力
 - ✓ **可伸缩性**：对大量数据，有效的构建模型的能力
 - ✓ **可解释性**：学习模型提供的理解和洞察的层次



4

分类与预测

➤ 用判定树归纳分类

- **什么是判定树？**

- ✓ 类似于流程图的树结构
- ✓ 每个内部节点表示在一个属性上的测试
- ✓ 每个分枝代表一个测试输出
- ✓ 每个树叶节点代表类或类分布

- **判定树的生成由两个阶段组成**

- ✓ **判定树构建**：开始时，所有的训练样本都在根节点；递归的通过选定的属性，来划分样本（必须是离散值）
- ✓ **树剪枝**：许多分枝反映的是训练数据中的噪声和孤立点，树剪枝试图检测和剪去这种分枝

- **判定树的使用：对未知样本进行分类**

- ✓ 通过将样本的属性值与判定树相比较



4

分类与预测

➤ 判定归纳树算法

- 判定归纳树算法（一个贪心算法）

- ✓ 自顶向下的分治方式构造判定树
- ✓ 树以代表训练样本的单个根节点开始
- ✓ 使用分类属性（如果是量化属性，则需先进行离散化）
- ✓ 递归的通过选择相应的测试属性，来划分样本，一旦一个属性出现在一个节点上，就不在该节点的任何后代上出现
- ✓ 测试属性是根据某种启发信息或者是统计信息来进行选择（如：信息增益）

- 递归划分步骤停止的条件

- ✓ 给定节点的所有样本属于同一类
- ✓ 没有剩余属性可以用来进一步划分样本——使用多数表决
- ✓ 没有剩余的样本



4

分类与预测

➤ 贝叶斯分类

- 贝叶斯分类利用统计学中的贝叶斯定理，来预测类成员的概率，即给定一个样本，计算该样本属于一个特定的类的概率。
- 朴素贝叶斯分类：假设每个属性之间都是相互独立的，并且每个属性对非类问题产生的影响都是一样的。

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$



4

分类与预测

➤ 后向传播分类

- 后向传播是一种神经网络学习算法；神经网络是一组连接的输入/输出单元，每个连接都与一个权相连。在学习阶段，通过调整神经网络的权，使得能够预测输入样本的正确标号来学习。
- **优点**
 - ✓ 预测精度总的来说较高
 - ✓ 健壮性好，训练样本中包含错误时也可正常工作
 - ✓ 输出可能是离散值、连续值或者是离散或量化属性的向量值
 - ✓ 对目标进行分类较快
- **缺点**
 - ✓ 训练（学习）时间长
 - ✓ 蕴涵在学习的权中的符号含义很难理解
 - ✓ 很难和专业领域知识相整合



4

分类与预测

➤ 其他分类方法

- **k-最临近分类**

- ✓ 给定一个未知样本，k-最临近分类法搜索模式空间，找出最接近未知样本的k个训练样本；然后使用k个最临近者中最公共的类来预测当前样本的类标号

- **基于案例的推理**

- ✓ 样本或案例使用复杂的符号表示，对于新案例，先检测是否存在同样的训练案例；如果找不到，则搜索类似的训练案例

- **遗传算法**

- ✓ 结合生物进化思想的算法

- **粗糙集方法**

- **模糊集方法**

- ✓ 允许在分类规则中定义“模糊的” 临界值或边界



4

分类与预测

➤ 什么是预测？

- 预测是构造和使用模型评估无样本类，或评估给定样本可能具有的属性或值空间。

➤ 预测和分类的异同

- **相同点**

- ✓ 两者都需要构建模型
- ✓ 都用模型来估计未知值：**线性回归和多元回归、非线性回归**

- **不同点**

- ✓ 分类法主要是用来预测类标号（分类属性值）
- ✓ 预测法主要是用来估计连续值（量化属性值）

4

分类与预测

➤ 回归方法

- **线性回归:** $Y = \alpha + \beta X$

✓ 其中 α 和 β 是回归系数, 可以根据给定的数据点, 通过最小二乘法来求得

$$\alpha = \bar{y} - \beta \bar{x}$$

$$\beta = \frac{\sum_{i=1}^S (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^S (x_i - \bar{x})^2}$$

- **多元回归:** $Y = \alpha + \beta_1 X_1 + \beta_2 X_2$
- 线性回归的扩展, 设计多个预测变量, 可以用最小二乘法求得上式中的 α , β_1 和 β_2
- **非线性回归:** $Y = \alpha + \beta_1 X_1 + \beta_2 X_2^2 + \beta_3 X_3^3$
 - ✓ 对不呈线性依赖的数据建模
 - ✓ 使用多项式回归建模方法, 然后进行变量变换, 将非线性模型转换为线性模型, 然后用最小二乘法求解



4

分类与预测

➤ 评估分类法的准确性

- 导出分类法后，再使用训练数据评估分类法，可能错误的导致乐观的估计
- 保持方法：
 - ✓ 给定数据随机划分为两个集合：训练集(2/3)和测试集(1/3)
 - ✓ 训练集导出分类法，测试集对其准确性进行评估
 - ✓ 随机子选样：保持方法的一个变形，将保持方法重复k次，然后取准确率的平均值
- k-折交叉确认
 - ✓ 初始数据被划分为k个不相交的，大小大致相同的子集 $S_1, S_2 \dots S_k$
 - ✓ 进行k次训练和测试，第i次时，以 S_i 做测试集，其他做训练集
 - ✓ 准确率为k次迭代正确分类数除以初始数据集样本总数



4

分类与预测

➤ 提高分类法的准确性

- Bagging技术和boosting技术都通过将T个学习得到的分类法 $C_1, C_2 \dots C_T$ 组合起来，从而创建一个改进的分类法 C^*
- Bagging技术
 - ✓ 对训练集S进行T次迭代，每次通过放回取样选取样本集 S_t ，通过学习 S_t 得到分类法 C_t
 - ✓ 对于未知样本X，每个分类法返回其类预测，作为一票
 - ✓ C^* 统计得票，并将得票最高的预测赋予X
- Boosting技术
 - ✓ 每个训练样本赋予一个权值
 - ✓ C_t 的权值取决于其错误率



5 异常值检测

- 异常检测是数据挖掘中一个重要方面，用来发现“小的模式”（相对于聚类），即数据集中显著不同于其它数据的对象。
- 异常探测应用
 - 电信和信用卡欺骗
 - 贷款审批
 - 药物研究
 - 气象预报
 - 金融领域
 - 客户分类
 - 网络入侵检测
 - 故障检测与诊断等



异常值检测

➤ 什么是异常?

- Hawkins(1980)给出了异常的本质性的定义：异常是在数据集中与众不同的数据，使人怀疑这些数据并非随机偏差，而是产生于完全不同的机制。
- 聚类算法对异常的定义：异常是聚类嵌于其中的背景噪声。
- 异常检测算法对异常的定义：异常是既不属于聚类也不属于背景噪声的点。他们的行为与正常的行为有很大不同。



5

异常值检测

➤ 异常检测方法的分类

- 异常检测就是发现与大部分其他对象不同的对象.异常的成因可以认为主要来自于以下几个方面:

①数据来源于不同的类;

②自然变异,即许多数据集可以用一个统计分布建模,如用正态(高斯)分布建模,其中数据对象的概率随到分布中心距离的增加而急剧减少,也就是说,大部分数据对象靠近中心,数据对象显著地不同于这个中心的似然性很小;

③数据测量和收集的失误。

以下为几种有代表性的检测异常值方法:

- ✓ 基于统计 (statistical-based)的方法
- ✓ 基于偏差(deviation-based)的方法
- ✓ 高维数据的异常探测

基于距离 (distance-based)的方法
基于密度(density-based)的方法



5

异常值检测

➤ 基于统计(statistical2based)的方法

- 基于统计方法是最早的异常点检测方法.对给定的数据集合假设概率模型,然后根据模型采用不一致性检验来确立异常点.基于统计的方法的主要缺点是:
 - ① 绝大多数检测都是针对单个属性的,而许多数据挖掘问题都要求在多维空间中发现异常;
 - ② 使用该方法需要事先知道数据的分布,但在大多数情况下,数据分布可能是未知的,所以,当没有特定的检验时,该方法不能确保发现所有的异常,或者观测到的分布不能恰当地被任何标准的分布来模拟;
 - ③ 通常对数值型数据有效,而对高维、周期性数据、分类数据则较难进行挖掘

5

异常值检测

➤ 基于距离(distance based)的方法

- 最早是由Knorr和Ng[2]在1998年提出的.数据集S中一个对象O称为DB(p,d) outlier, 如果它满足下列性质:数据集S中至少 $p \times 100\%$ 的对象与O的距离大于距离d.采用不同的参数p和d,DB(p,d)可以表示所有的基于统计的异常点.
- 与基于统计的方法相比,基于距离的异常点检测拓广了不一致性检验的思想.与此定义相应的算法有3种:基于索引(index based)的算法[3]、嵌套循环(nested loop)算法[4-5]、基于单元或划分(cell based)的算法[6].

1) 基于索引的方法依赖多维索引结构(R-trees, X-trees, KD-trees等)的性能.它可以通过对最近邻查询或以O为中心的范围查询的回答来实现寻找所有DB(P,D) outlier.基于多维索引结构R-Tree或kd-Tree算法复杂度是 $O(KN^2)$,其中K是维数,N是数据点数.但它的缺点是需要建立多维索引结构,比较费时,同时随着维数的增加所有的索引结构的性能迅速下降,使得算法性能不佳.



5

异常值检测

➤ 基于距离(distance based)的方法

2)嵌套循环算法是将内存缓冲区空间划分成相等的2部分,数据集分成几个缓冲区大小相等的逻辑块,通过认真选择调入每一部分缓冲区的次序,使I/O次数最小.嵌套循环算法和基于索引的算法有相同的计算复杂度,算法复杂度为 $O(KN^2)$,其中K表示维数,N表示数据点数.它的特点是不需要建立多维索引结构,通过次序的选择试图最小化I/O的次数.它把内存的缓冲空间分为两半,把数据集分为若干个缓冲区大小相等的逻辑块,通过精心选择逻辑块装入每个缓冲区的顺序,使I/O效率能够改善,但选择划分区域也较费时,当遇到大量数据集时还有待改进.

3)基于单元或划分的算法.相对前两者,基于单元的算法无论是在数据量或维数增加时,性能都是最好的.此方法需要将数据空间分隔成彼此独立的单元结构,经过多次选择来判断离群数据,但对于参数的每个变化都需要调整单元结构,因此会影响了算法的结果.Knorr和Ng通过试验证明:当 $k \leq 4$ 时此算法优于NL算法;但当 $k \geq 5$ 之后,嵌套循环算法开始显现出优势.



5

异常值检测

➤ 基于偏离(deviation2based)的方法

- 基于偏离的异常点挖掘是不采用统计检验或基于距离的度量值来确定异常点的,相反,它通过检查一组对象的主要特征来确定异常点,与给出的描述相“偏离”的对象被认为是异常点.

1)序列异常技术.Argrawal和Ragaran[7]提出一种“序列异常点(sequential exception)”的概念.这个算法复杂度与数据集大小呈线性关系,有优异的计算性能,但是对异常点存在的假设太过理想化,对现实复杂数据的处理效果不太好.

2)OLAP数据立方体技术.偏离探测的OLAP方法在大规模的多维数据中采用数据立方体确定反常区域,如果一个立方体的单元值显著地不同于根据统计模型得到的期望值,则该单元值被认为是一个异常点.

5

异常值检测

➤ 基于密度(density2based)的方法

- 基于密度方法是在基于距离的方法上改进而来,能够检测出基于距离异常算法所不能识别的局部异常.局部异常观点摒弃了以前所有的异常定义中非此即彼的绝对异常观念,更加符合现实生活中的应用.
- Breunig,Kriegel和Sander提出了基于密度的异常点概念.
- 对象 p 的 k -距离($k2distance$):对任意的自然数 k ,定义 p 的 k -距离($k2distance(p)$)为 p 和某个对象 o 之间的距离.这里的 o 满足:①至少存在 k 个对象 $o' \in D \setminus \{p\}$,使得 $d(p,o') < d(p,o)$;②至多存在 $k-1$ 个对象 $o' \in D \setminus \{p\}$,使得 $d(p,o') < d(p,o)$.对象 p 的 k -距离邻域($Nk2distance$):给定 p 的 $k2distance(p)$, p 的 k -距离邻域包含所有与 p 的距离不超过 $k2distance(p)$ 的对象,即 $Nk2distance(p) = \{q | d(p,q) \leq k2distance(p)\}$
- 对象 p 相对于对象 o 的可达距离:给定自然数 k ,对象 p 相对于对象 o 的可达距离 $reachdistk(p,o) = \max\{k2distance(o), d(p,o)\}$.

5

异常值检测

➤ 基于密度(density2based)的方法

- 对象p的局部可达密度(LocalReachableDistance)为对象p与它的MinPts-邻域的平均可达距离的倒数,即

$$d_{MinPts}(p) = \left[\frac{\sum_{o \in N_{MinPts}(p)} reach-dist_{MinPts}(p, o)}{|N_{MinPts}(p)|} \right]^{-1}$$

- 对象p的局部异常点因子(LocalOutlierFactor):

$$lof_{MinPts}(p) = \frac{\sum_{o \in N_{MinPts}(p)} \frac{d_{MinPts}(o)}{d_{MinPts}(p)}}{|N_{MinPts}(p)|}$$

- 对象P的局部异常点因子表示p的异常点程度.局部异常点因子愈大,就认为它更可能是异常点;反之则可能性小.簇内靠近核心点的对象的LOF接近于1,那么不应该被认为是局部异常点.而处于簇的边缘或是簇的外面的对象的LOF相对较大.

5

异常值检测

➤ 高维数据的异常点检测

- Aggarwal和Yu提出一个高维数据异常点检测的方法.它把高维数据集映射到低维子空间,根据子空间映射数据的稀疏程度来确定异常点数据是否存在.高维数据的异常点检测算法思想为将数据空间的每一维分成 δ 个等深度区间.所谓等深度区间是指将数据映射到此一维空间上后,每一区间包含相等的 $f=1/\delta$ 的数据点.在数据集的 k 维子空间中的每一维上各取一个等深度区间,组成一个 k 维立方体,则立方体中的数据映射点数为随机数 ϵ 设 $n(D)$ 为 k 维立方体 D 所包含点数, N 为总的点数.定义稀疏系数 $s(D)$ 为:

$$s(D) = \frac{n(D) - N * f^k}{\sqrt{N * f^k(1 - f^k)}}$$

- $s(D)$ 为负数时,说明立方体 D 中数据点低于期望值, $s(D)$ 越小,说明此立方体中数据越稀疏.在高维数据中寻找异常点模式是非常困难的.一个简单办法是对所有数据维进行组合来搜索可能的异常点模式,但是效率极其低下.



5

异常值检测

➤ 高维数据的异常点检测优化

- Aggarwal和Yu运用遗传算法优化这个问题的求解过程:它以随机选择的P个合法模式作为候选解开始,反复经历选择,交叉,变异等几个过程,直至得到较满意的解.①选择:对于候选解,即合法模式,计算其稀疏系数,并以此依据排序,稀疏系数越小,说明该模式异常点程度大,被选择的概率越大,直至选出新的p个候选解.②交叉:采用了一个优化的交叉算法.③变异:设Q为值是3的位置的集合,变异只发生在非Q类位置,有2种变异类型:类型1,将变异位置置为3,然后在Q中间选择一个位置,随机置为1到 δ 个数即可;类型2,将变异位置随机置为1到 δ 中间的一个值



感谢观看